

Acadêmico: **Arthur Chiarato Gorini Gomes** R.A.: **23016363-2**

Curso: **ENGENHARIA DE SOFTWARE** Disciplina: **INTELIGÊNCIA ARTIFICIAL**

INSTRUÇÕES PARA REALIZAÇÃO DESTA ATIVIDADE

Preparação de dados - Exercícios

1 Conceitual – Importância da Preparação

Explique por que a etapa de preparação de dados pode impactar mais o desempenho de um modelo do que a escolha do algoritmo de Machine Learning.

2 Valores Ausentes

Considere um dataset com 10.000 registros onde 25% das entradas da variável `idade` estão ausentes.

- Quais são as possíveis estratégias para tratar esses valores?
- Em quais situações remover registros é inadequado?

3 Normalização vs Padronização

Explique a diferença entre:

- Normalização (Min-Max)
- Padronização (Z-score)

Em quais tipos de algoritmos cada uma é mais recomendada? Justifique.

4 Dados Categóricos

Você possui a variável:

«» Código

```
clima = {sol, chuva, nublado}
```



- a) Como transformar essa variável para uso em um modelo de Machine Learning?
b) Qual problema pode ocorrer se utilizarmos apenas codificação numérica simples (0,1,2)?

5 Overfitting e Separação de Dados

Explique por que dividimos o dataset em:

- Treino
- Validação
- Teste

O que acontece se utilizarmos o conjunto de teste durante o treinamento?

6 Balanceamento de Classes

Considere um problema onde:

- 95% das amostras pertencem à classe A
- 5% pertencem à classe B

- a) Qual problema pode ocorrer?
b) Cite duas técnicas para tratar esse desbalanceamento.

UniCesumar

7 Detecção de Outliers

Explique:

- a) O que são outliers
 - b) Quando removê-los pode prejudicar o modelo
 - c) Um método estatístico para detectá-los
-

8 Feature Engineering

Dado o dataset:


```
«» Código  
data_nascimento
```



Explique por que criar a variável `idade` pode ser melhor do que usar diretamente a data de nascimento.

9 Pipeline de Pré-processamento

Descreva um pipeline completo de preparação para um dataset que contém:

- Valores ausentes
 - Dados categóricos
 - Variáveis com escalas diferentes
 - Classes desbalanceadas
- 

10 Estudo de Caso Aplicado

Você recebeu um dataset para prever aprovação em crédito bancário.

Variáveis:

- renda_mensal
- idade
- estado_civil
- número_de_dependentes
- histórico_de_inadimplência

Descreva todas as etapas de preparação antes de treinar o modelo.

Seja específico.

1. Importância da Preparação de Dados

A etapa de preparação de dados pode impactar mais o desempenho de um modelo do que a escolha do algoritmo porque os modelos de Machine Learning aprendem padrões diretamente dos dados. Se os dados estiverem incompletos, inconsistentes, com ruído ou mal escalados, o modelo pode aprender padrões incorretos.

Dados mal preparados podem causar:

- vieses no modelo
- baixa precisão
- overfitting
- dificuldade de convergência

Por isso, limpar, transformar e organizar os dados corretamente é fundamental para que o algoritmo consiga aprender padrões reais.

2. Valores Ausentes

a) Possíveis estratégias

Algumas estratégias para tratar valores ausentes são:

- Remover registros com valores ausentes
- Preencher com média, mediana ou moda
- Preencher com um valor constante (ex: “desconhecido”)

- Estimar os valores utilizando modelos preditivos
 - Utilizar algoritmos que aceitam valores ausentes
-

b) Quando remover registros é inadequado

Remover registros pode ser inadequado quando:

- uma grande parte dos dados possui valores ausentes
- o dataset é pequeno
- a variável é muito importante para o modelo
- a remoção pode gerar viés nos dados

Por exemplo, remover 25% dos dados pode prejudicar o treinamento do modelo.

3. Normalização vs Padronização

Normalização (Min-Max)

Transforma os valores para um intervalo específico, normalmente **entre 0 e 1**.

Fórmula:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Ela preserva a distribuição dos dados.

Padronização (Z-score)

Transforma os dados para que tenham **média 0 e desvio padrão 1**.

$$z = \frac{x - \mu}{\sigma}$$

Fórmula:

Quando usar cada uma

Normalização (Min-Max)

Mais recomendada para:

- KNN
- Redes neurais
- algoritmos baseados em distância

Padronização (Z-score)

Mais recomendada para:

- Regressão logística
- SVM
- algoritmos que assumem distribuição normal

4. Dados Categóricos

Variável:

clima = {sol, chuva, nublado}

a) Como transformar

Podemos utilizar **One-Hot Encoding**.

Exemplo:

so	chuv	nublad
l	a	o
1	0	0
0	1	0
0	0	1

b) Problema da codificação numérica simples

Se utilizarmos:

sol = 0

chuva = 1

nublado = 2

O modelo pode interpretar que existe uma **ordem entre as categorias**, o que não é verdadeiro.

Isso pode gerar **interpretação incorreta dos dados**.

5. Overfitting e Separação de Dados

Dividimos o dataset em:

Treino

Usado para treinar o modelo.

Validação

Usado para ajustar hiperparâmetros e escolher o melhor modelo.

Teste

Usado apenas para avaliar o desempenho final do modelo.

O que acontece se usarmos o teste no treinamento?

Se o conjunto de teste for usado no treinamento:

- ocorre **vazamento de dados (data leakage)**
- o modelo fica **superajustado**
- a avaliação deixa de ser confiável

Ou seja, o desempenho medido não representa a realidade.

6. Balanceamento de Classes

Situação:

95% classe A

5% classe B

a) Problema

O modelo pode aprender a prever **sempre a classe A**, pois isso já gera 95% de acerto.

Isso faz com que o modelo **ignore a classe minoritária**, prejudicando a detecção dela.

b) Técnicas para resolver

Algumas técnicas:

- **Oversampling** (ex: SMOTE)
 - **Undersampling**
 - Ajuste de pesos das classes
 - Geração de dados sintéticos
-

7. Detecção de Outliers

a) O que são outliers

Outliers são **valores muito diferentes do restante dos dados**, que estão fora do padrão esperado da distribuição.

Eles podem ocorrer por:

- erros de medição
 - erros de registro
 - eventos raros
-

b) Quando remover pode prejudicar

Remover outliers pode prejudicar quando:

- eles representam **eventos reais importantes**
 - são **casos raros que queremos detectar** (ex: fraude)
-

c) Método estatístico para detectar

Alguns métodos:

- **Boxplot (IQR)**
- **Z-score**
- **Desvio padrão**

Exemplo: considerar outlier valores acima de **3 desvios padrão da média**.

8. Feature Engineering

Variável original:

`data_nascimento`

Criar a variável **idade** é melhor porque:

- facilita o aprendizado do modelo
- reduz complexidade
- transforma a informação em algo diretamente útil

Por exemplo:

`idade = ano_atual - ano_nascimento`

O modelo entende melhor **idade** do que **datas completas**.

9. Pipeline de Pré-processamento

Um pipeline possível:

1 Limpeza de dados

- identificar valores ausentes
- preencher ou remover

2 Tratamento de dados categóricos

- aplicar One-Hot Encoding

3 Escalonamento de variáveis

- normalização ou padronização

4 Tratamento de outliers

- identificar e remover ou suavizar

5 Balanceamento de classes

- usar SMOTE ou undersampling

6 Divisão do dataset

- treino
- validação
- teste



UniCesumar

10. Estudo de Caso – Crédito Bancário

Variáveis:

- renda_mensal

- idade
 - estado_civil
 - numero_de_dependentes
 - historico_de_inadimplencia
-

Etapas de preparação

1. Análise exploratória

Verificar:

- valores ausentes
 - distribuição dos dados
 - possíveis outliers
-

2. Tratamento de valores ausentes

- preencher renda e idade com média ou mediana
 - estado civil com moda
-

3. Tratamento de dados categóricos

Transformar `estado_civil` usando One-Hot Encoding.

4. Detecção de outliers

Verificar valores extremos em:

- renda
- número de dependentes

Remover ou ajustar se necessário.

5. Normalização ou padronização

Aplicar escala em variáveis numéricas:

- renda
 - idade
 - número de dependentes
-

6. Balanceamento de classes

Se houver poucas aprovações ou reprovações, aplicar técnicas como:

- SMOTE
- undersampling

7. Divisão do dataset

Separar em:

- 70% treino
 - 15% validação
 - 15% teste
-

8. Treinamento do modelo

Após a preparação, o modelo pode ser treinado com algoritmos como:

- Random Forest
- Regressão logística
- Gradient Boosting