

Acadêmico: **Arthur Chiarato Gorini Gomes**

R.A.:

23016363-2Curso: **ENGENHARIA DE SOFTWARE**

Disciplina:

**INTELIGÊNCIA
ARTIFICIAL****INSTRUÇÕES PARA REALIZAÇÃO DESTA ATIVIDADE**

Sobre modelos múltiplos responda.

Como combinar as previsões dos diferentes modelos? (1 a duas frases cada 1)

Métodos de votação vs. métodos de seriação → fusão de classificadores**Métodos de votação**

Nos métodos de votação, cada modelo faz sua previsão e a decisão final é escolhida pela maioria dos votos. Também existe a votação ponderada, onde modelos com melhor desempenho possuem mais influência no resultado final.

Métodos de seriação

Nos métodos de seriação, os modelos não retornam apenas uma classe, mas sim uma ordem de preferência ou pontuações para cada classe. A decisão final considera esses valores para encontrar a classe mais adequada.

Métodos estáticos vs. métodos dinâmicos

Métodos estáticos

Nos métodos estáticos, os modelos utilizados na classificação permanecem os mesmos para qualquer exemplo analisado. Ou seja, a combinação não muda dependendo da entrada.

Métodos dinâmicos

Nos métodos dinâmicos, o sistema escolhe qual modelo utilizar de acordo com as características do exemplo que está sendo classificado. Isso permite uma adaptação maior para diferentes situações.

Existem métodos dinâmicos levam em consideração o exemplo que está sendo

Explique: (1 a duas frases cada 1)

MAI - Model Applicability Induction

SCANN - Análise de Correspondência Seguida por um Vizinho Mais Próximo

MAI - Model Applicability Induction

O MAI é uma técnica que aprende qual modelo apresenta melhor resultado para determinados tipos de dados. Assim, dependendo das características da entrada, ele escolhe automaticamente o classificador mais adequado.

SCANN - Análise de Correspondência Seguida por um Vizinho Mais Próximo

O SCANN organiza os dados em um espaço de similaridade e utiliza o método do vizinho mais próximo para encontrar exemplos parecidos. Dessa forma, a classificação é feita considerando elementos próximos e semelhantes.

Explique os conceitos em conjunto: 1 parágrafo cada 1

BOOSTRAP - BAGGING - BOOSTING - ADABOOST

Bootstrap

Bootstrap é uma técnica utilizada para criar várias amostras diferentes a partir de um mesmo conjunto de dados. Essas amostras são geradas aleatoriamente com reposição, permitindo que um mesmo registro apareça mais de uma vez. Essa abordagem é bastante utilizada em aprendizado de máquina para aumentar a diversidade dos dados usados no treinamento dos modelos.

Bagging

Bagging é uma técnica que utiliza várias amostras geradas pelo bootstrap para treinar diversos modelos de forma independente. Depois disso, os resultados são combinados, normalmente por votação ou média. O principal objetivo do bagging é reduzir erros causados por variações nos dados e tornar o modelo mais estável.

Boosting

Boosting é um método onde os modelos são treinados em sequência, e cada novo modelo tenta corrigir os erros cometidos pelo anterior. Diferente do bagging, existe dependência entre os modelos. Essa técnica costuma melhorar bastante a precisão do sistema, principalmente em problemas mais complexos.

Adaboost

AdaBoost é um algoritmo de boosting que dá mais atenção aos exemplos classificados incorretamente durante o treinamento. A cada nova etapa, os dados com mais erro recebem maior peso, fazendo com que o próximo modelo foque neles. No final, todos os modelos são combinados para gerar uma classificação mais eficiente.

Explique o método 1 parágrafo

Random Forest

Random Forest é um método baseado em várias árvores de decisão criadas a partir de subconjuntos aleatórios dos dados e dos atributos. Cada árvore faz sua própria previsão e, no final, ocorre uma votação para decidir o resultado final. Essa técnica reduz overfitting e normalmente apresenta boa precisão em problemas de classificação e regressão.

Explique o método 1-3 parágrafos

Stacking

Stacking é uma técnica de combinação de modelos onde vários classificadores são treinados ao mesmo tempo e suas previsões são usadas como entrada para um modelo final, chamado meta-modelo. Esse meta-modelo aprende como combinar os resultados dos classificadores iniciais da melhor forma possível.

Diferente da votação simples, o stacking tenta identificar em quais situações cada modelo possui melhor desempenho. Isso permite criar uma combinação mais inteligente entre os classificadores, melhorando a capacidade de generalização.

Para evitar overfitting, normalmente é utilizada validação cruzada durante o treinamento. Apesar de apresentar bons resultados, o stacking possui implementação mais complexa e maior custo computacional em comparação com métodos mais simples

UniCesumar



